

1. max 的平滑近似:

$$\begin{aligned} \text{Max}(a, b) &\approx \log(e^a + e^b) \\ \text{Max}(x_1, x_2, \dots, x_n) &\approx \log \sum_{i=1}^n e^{x_i} \\ \text{Relu}(x) = \text{Max}(x, 0) &\approx \log(1 + e^x) \end{aligned}$$

本质上是找到一个导数增长比线性更快的函数（这里是  $e^x$ ），拉开数值差距，相加后再取导函数（log）

同理也可以取先平方和再开根号，但是二次函数的导数增长没有指数快，所以近似效果没那么好

2. Softmax+交叉熵作为损失函数的推导:

$y = f(x) = (y_1, y_2, \dots, y_n)$  为网络输出, 其中  $y_k$  为真值对应的分数

我们希望  $y_k > y_i$ , 其中  $i \neq k$ , 定义损失函数  $L$ :

$L = \max \left\{ \max_{i \neq k} \{y_i\} - y_k, 0 \right\}$ ,  $\Leftrightarrow$  理解为希望  $y_k$  比其它值中最大的更大

$\Updownarrow$  用  $\log \sum e^{x_i} \approx \max \{x_i\}$ , 平滑近似 max 函数

$$\begin{aligned} L &\approx \max \left\{ \log \sum_{i \neq k} e^{y_i} - y_k, 0 \right\} \\ &\approx \log \left[ e^0 + e^{\left( \log \sum_{i \neq k} e^{y_i} - y_k \right)} \right] \\ &= \log \left( 1 + \frac{\sum_{i \neq k} e^{y_i}}{e^{y_k}} \right) \\ &= \log \left( \frac{e^{y_k}}{e^{y_k}} + \frac{\sum_{i \neq k} e^{y_i}}{e^{y_k}} \right) \\ &= \log \frac{\sum e^{y_i}}{e^{y_k}} \\ &= -\log \frac{e^{y_k}}{\sum e^{y_i}} \\ &\Rightarrow L \approx -\log \frac{e^{y_k}}{\sum e^{y_i}} \end{aligned}$$

3. Margin 推导:

更进一步, 我们不但希望  $y_k$  比  $y_i$  大

$$\Rightarrow y_k > y_i, \forall i \neq k.$$

还希望  $y_k$  比  $y_i$  大一个距离  $m$ :

$$\Rightarrow y_k > y_i + m, \forall i \neq k$$

$$\Rightarrow y_k - m > y_i, \forall i \neq k.$$

将  $y_k - m$  代入到刚推导的 ~~log~~ ~~loss~~

$$L = -\log \frac{e^{y_k}}{e^{y_k} + \sum_{i \neq k} e^{y_i}} \text{ 的 } y_k \text{ 中 (换元, 重新推也可以有一样的结果)}$$

$$\Rightarrow L = -\log \frac{e^{y_k - m}}{e^{y_k - m} + \sum_{i \neq k} e^{y_i}}$$

更一般的形式:

更一般的,  $m$  可以不是一个固定的常数

可以取  $m$  为  $y_k$  的函数

$$m = \phi(y_k) > 0 \quad (\text{我们希望间隔大于 } 0)$$

$$\text{设 } g(y_k) = y_k - \phi(y_k) = y_k - m$$

有

$$L = -\log \frac{e^{g(y_k)}}{e^{g(y_k)} + \sum_{i \neq k} e^{y_i}} \quad \text{为 margin 的一般形式 (1)}$$

不难看出, surface, normalce 等都是 (1) 式的特例

我们可以自己构造新的 margin-softmax.

$$\text{如: 取 } \phi(y_k) = (1 - y_k)^2$$

$$\Rightarrow y_k - (1 - y_k)^2$$

$$L_{\text{new}} = -\log \frac{e^{y_k - (1 - y_k)^2}}{e^{y_k - (1 - y_k)^2} + \sum_{i \neq k} e^{y_i}} \quad (\text{随便构造的})$$

逻辑上合理, 真实效果未测试

#### 4. 多正样本（多对多）推导：

之前为 1 个正样本,  $n$  个负样本,  
 假设现在有  $m$  个正样本,  $n$  个负样本:  $\{x_1, x_2, \dots, x_m, x_{m+1}, \dots, x_{m+n}\}$   
 设正样本下标:  $\{i_1, i_2, \dots, i_m\}$ , 负样本下标  $\{j_1, j_2, \dots, j_n\}$ .

$$L = \max_i \left\{ \max_j \{y_{i i_1}\} - \min_j \{y_{i j_1}\}, 0 \right\} \Leftrightarrow \text{希望最小的正分数比最大负分数还大.}$$

$$\begin{aligned} & \boxed{\min\{x\} = -\max\{-x\}} \\ & \text{把 min 换成 max, 再用 max 的平滑近似} \end{aligned}$$

$$\begin{aligned} L &\approx \max_i \left\{ \log \sum_j e^{y_{i i_1}} + \log \sum_j e^{-y_{i j_1}}, 0 \right\} \\ &= \max_i \left\{ \log \left( \sum_j e^{y_{i i_1}} \cdot \sum_j e^{-y_{i j_1}} \right), 0 \right\} \\ &= \log \left( e^0 + e^{\log \left( \sum_j e^{y_{i i_1}} \cdot \sum_j e^{-y_{i j_1}} \right)} \right) \\ &= \log \left[ 1 + \sum_i e^{y_{i i_1}} \cdot \sum_j e^{-y_{i j_1}} \right] \end{aligned}$$

这就是时视 Circle loss 最简单的形式.  
 有兴趣可以加上 margin 推一遍.