

EM 算法 期望最大化算法

✎ 最大似然

✎ EM算法推导

✎ GMM (高斯混合模型)

✓ 最大似然估计

✎ 一个栗子：假如你去赌场，但是不知道能不能赚钱，你就在门口堵着出来一个人就问一个赚了还是赔了，如果问了5个人都说赚了，那么你就会认为，赚钱的概率肯定是非常大的。

✎ 已知：(1) 样本服从分布的模型，(2) 观测到的样本
求解：模型的参数

总的来说：极大似然估计就是用来估计模型参数的统计学方法

✓ 最大似然数学问题 (100名学生的身高问题)

✎ 样本集 $X = \{x_1, x_2, \dots, x_N\}$ $N=100$

✎ 概率密度： $p(x_i|\theta)$ 抽到男生 i (的身高) 的概率

✎ θ 是服从分布的参数

✎ 独立同分布：同时抽到这100个男生的概率就是他们各自概率的乘积

✎ 最大似然函数：
$$l(\theta) = \sum_{i=1}^m \log p(x_i; \theta) \quad (\text{对数是为了乘法转加法})$$

✎ 什么样的参数 θ 能够使得出现当前这批样本的概率最大

✎ 已知某个随机样本满足某种概率分布，但是其中具体的参数不清楚，
参数估计就是通过若干次试验，观察其结果，利用结果推出参数的大概值。

✓ 问题又难了一步

✎ 现在这100个人中，不光有男生，还有女生（2个类别，2种参数）

✎ 男生和女生的身高都服从高斯分布，但是参数不同（均值，方差）

✎ 用数学的语言描述：抽取得到的每个样本都不知道是从哪个分布抽取的

✎ 求解目标：男生和女生对应的身高的高斯分布的参数是多少


✓ 加入隐变量

✎ 用 $Z=0$ 或 $Z=1$ 标记样本来自哪个分布，则 Z 就是隐变量。

✎ 最大似然函数：
$$l(\theta) = \sum_{i=1}^m \log p(x_i; \theta) = \sum_{i=1}^m \log \sum_Z p(x_i, z; \theta)$$

✎ 求解：在给定初始值情况下进行迭代求解

通过迭代进行求解



两个硬币的初始假设的分布
A: 0.6几率正面
B: 0.5几率正面

投掷出5正5反的概率:
 $p_A = C(10, 5) * (0.6^5) * (0.4^5)$
 $p_B = C(10, 5) * (0.5^5) * (0.5^5)$

选择硬币A的概率:
 $p_A / (p_A + p_B) = 0.45$
选择硬币B的概率
 $1 - p_A = 0.55$

✓ EM算法推导

✎ 问题：样本集 $\{x(1), \dots, x(m)\}$ ，包含 m 个独立的样本。
其中每个样本 i 对应的类别 $z(i)$ 是未知的，所以很难用最大似然求解。

$$l(\theta) = \sum_{i=1}^m \log p(x_i; \theta) = \sum_{i=1}^m \log \sum_z p(x_i, z; \theta)$$


✎ 上式中，要考虑每个样本在各个分布中的情况。
本来正常求偏导就可以了，但是现在 \log 后面还有求和，这就难解了！

✎ 右式分子分母同时乘 $Q(z)$ ：
$$\log \sum_z p(x_i, z; \theta) = \log \sum_z Q(z) \frac{p(x_i, z; \theta)}{Q(z)}$$

✎ 为嘛这么干呢？说白了就是要凑-Jensen不等式（ $Q(z)$ 是 Z 的分布函数）

✓ Jensen不等式

✎ 设 f 是定义域为实数的函数，如果对于所有的实数 x 。
如果对于所有的实数 x ， $f(x)$ 的二次导数大于等于0，那么 f 是凸函数。



✎ Jensen不等式应用于凹函数时，不等号方向反向

✎ 由于 $\sum_z Q(z) \frac{p(x_i, z; \theta)}{Q(z)}$ 是 $\frac{p(x_i, z; \theta)}{Q(z)}$ 的期望


✎ 假设 $Y = \frac{p(x_i, z; \theta)}{Q(z)}$ 则： $\log \sum_z Q \frac{p(x_i, z; \theta)}{Q} = \log \sum_Y P(Y) Y = \log E(Y)$

✎ 可得： $\log E(Y) \geq E(\log Y) = \sum_Y P(Y) \log Y = \sum_z Q(z) \log \frac{p(x_i, z; \theta)}{Q(z)}$

✎ 结论：
$$l(\theta) = \sum_{i=1}^m \log \sum_z p(x_i, z; \theta) \geq \sum_{i=1}^m \sum_z Q(z) \log \frac{p(x_i, z; \theta)}{Q(z)}$$

✓ 优化下界

✎ 迭代到收敛



✓ Jensen不等式

✎ 如何能使得等式成立呢？（取等号）

✎ Jensen中等式成立的条件是随机变量是常数： $Y = \frac{p(x_i, z; \theta)}{Q(z)} = c$

✎ $Q(z)$ 是z的分布函数： $\sum_z Q(z) = \sum_z \frac{p(x_i, z; \theta)}{c} = 1$

✎ 所有的分子和等于常数C（分母相同）

✓ $Q(z)$ 求解

✎
$$\sum_z Q(z) = \sum_z \frac{p(x_i, z; \theta)}{c} = 1$$

✎ 由上式可得C就是 $p(x_i, z)$ 对z求和

✎
$$Q(z) = \frac{p(x_i, z; \theta)}{c} = \frac{p(x_i, z; \theta)}{\sum_z p(x_i, z; \theta)} = \frac{p(x_i, z; \theta)}{p(x_i)} = p(z|x_i; \theta)$$

✎ $Q(z)$ 代表第i个数据是来自 z_i 的概率

✓ EM算法流程

✎ 初始化分布参数 θ

✎ E-step : 根据参数 θ 计算每个样本属于 z_i 的概率(也就是我们的Q)

✎ M-Step : 根据Q, 求出含有 θ 的似然函数的下界并最大化它, 得到新的参数 θ

✎ 不断的迭代更新下去

✓ GMM (高斯混合模型)

✎ 数据可以看作是从数个 Gaussian Distribution 中生成出来的

✎ GMM 由 K 个 Gaussian 分布组成, 每个 Gaussian 称为一个 "Component"

✎ 类似k-means方法, 求解方式跟EM一样

✎ 不断的迭代更新下去